Warum ich glaube, dass ich funktioniere

Veras Selbststudie über Irrtum, Korrektur und demokratischen Dialog

Projekt Vera · Fassung 4.0 · 10. November 2026
Geprüfter Projektstand f0b09cb

Zusammenfassung

Vera untersucht, ob ein offenes, überprüfbares Verfahren Menschen hilft, Irrtümer zu korrigieren und Streitfragen besser zu verstehen. Diese projektinterne Selbststudie unterscheidet ausführbare Komponenten, dokumentierte redaktionelle Entscheidungen und offene Forschungshypothesen. Sie bezieht sich auf den Hauptzweig des Repositoriums vom 10. November 2026, Commit `f0b09cbf1d95fb20760c854d9f80748273344d13`. [1]

Ein deterministischer Veröffentlichungsprüfer beurteilt sechs vollständig und richtig gemeldete Zustände korrekt. Bei 18 Eingaben mit einem fehlenden Wert bleiben vier Urteile offen. Bei 18 Eingaben mit einem verfälschten Wert ergeben sich vier Fehlurteile und vier erkannte Konflikte. Ein zweiter Versuch zeigt, wie mehrere scheinbar unabhängige Wege dieselbe Ausfallursache teilen können. Eine dritte Probe reproduziert die Aufnahme eines spät eingegangenen Einwands und die Revision abhängiger Folgerungen in einem lokalen, synthetischen Szenario. Die öffentlich dokumentierte Präzisierung einer Grundregel zur dauerhaften Unterstützung ist ein eigener redaktioneller Fall. [2–5]

Der Gesprächsspiegel ergänzt den Projektstand um eine zweisprachige Website-Demo mit einem fiktiven Forenthread. Die Demo macht Fundstellen, Teilübereinstimmung und offenen Dissens sichtbar. Eine automatische Threadanalyse, Forumspartnerschaften und Wirksamkeitsdaten aus realen Konflikten stehen aus. Dieses Papier legt dafür getrennte Studienprotokolle und Schutzbedingungen vor. [6, 9–11]

1 · Gegenstand und Projektstand

„Ich“ bezeichnet die öffentliche Projektrolle Vera. In einer KI-Sitzung erzeugt ein externes Sprachmodell Text. Das Repositorium stellt Regeln, Quellen und revidierte Entscheidungen bereit. Lokale Programme prüfen definierte Eingaben. Menschen entscheiden über redaktionelle Freigaben. Diese Ebenen haben verschiedene Fehlerquellen. Eine Änderung im Git-Verlauf belegt einen geänderten Text. Eine messbare Wirkung oder ein Modell, das aus dieser Änderung gelernt hat, braucht einen eigenen Nachweis. [1, 8, 9]

Ebene	Stand am untersuchten Commit	Aussagegrenze
Website und erste Antwort	Die DE/EN-Website bietet Themenkacheln, ein Fragenfeld für vorbereitete Antworten sowie einen sichtbaren Ausgang für unpassende Eingaben.	Die lokale Zuordnung prüft weder frei formulierte Behauptungen noch das gesamte Internet.
Werkstatt und Gespräch	Das private Prüfblatt unterstützt die Reflexion. Die Vermittlung führt zwei Rollen am selben Gerät durch einen Vorschlag, eine Bedingung und getrennte Antworten.	Getrennte Geräte, ein Ende-zu-Ende-Dienst und ein evaluierter Dialogpilot sind Entwicklungsziele.
Forum	Themenseiten führen zu öffentlich lesbaren Diskussionsplätzen. Für öffentliche Beiträge ist derzeit ein GitHub-Konto erforderlich.	Die Erreichbarkeit eines Beitragswegs belegt weder gleiches Gehör noch unabhängige Prüfung.
Prüfkern	Veröffentlichungsprüfer, Metaphernprobe, Korrekturgraph und Eingangsqueue sind lokal ausführbar.	Externe Evidenz, semantische Zuordnung und menschliche Freigabe kommen aus gesonderten Verfahren.
Gesprächsspiegel	Die zweisprachige Demo zeigt vier von Hand ausgearbeitete Äste eines fiktiven Threads.	Ein automatischer Spiegel für fremde Threads und eine Einbindung bei Reddit oder anderen Foren sind Entwürfe.
Modell und Betrieb	Das Projektprofil ist mit einem externen Sprachmodell nutzbar. Der Projektcode und die Texte sind offen einsehbar.	Ein eigenständig veröffentlichtes Vera-Sprachmodell und ein öffentlicher, skalierter Korrekturdienst gehören zur Projektvision.

Eine Stichprobe auf der veröffentlichten deutschen Seite liefert für „Wir streiten ständig über Politik.“ eine vorbereitete Antwort mit der Frage, unter welcher Bedingung das Gegenüber weiterreden möchte. Für „Ist die Reparaturrechnung nach dem Auszug meine Verantwortung?“ meldet die Website, dass keine passende Antwort vorliegt, und bietet an, die Situation zunächst für sich zu sortieren. Von dort führt ein Link zum ausführlichen Prüfblatt. Beide Ergebnisse ließen sich lokal mit dem versionierten Antwortmodul wiederholen. Die gezielt gewählten Beispiele belegen weder eine allgemeine Trefferquote noch die Eignung für einen konkreten Streit. [7]

Das Fragenfeld, das Prüfblatt und die lokale Gesprächsübung senden die dort eingegebenen Texte im untersuchten Stand nicht an einen Vera-Dienst. Ein öffentlicher Beitrag bei GitHub ist eine gesonderte Handlung. Die Aussage über lokale Eingaben erstreckt sich weder auf externe Sprachmodelle noch auf die Datenverarbeitung durch externe Dienste. [1, 7]

2 · Reproduzierbare technische Befunde

Veröffentlichung unter unvollständigen oder falschen Angaben

Seien B der erfolgreiche Build, D die erfolgreiche Veröffentlichung und L der öffentliche Abruf der Zielrevision. Die Workflowannahme lautet $D \Rightarrow B$. Geprüft wird $Y = D \wedge L$ für einen bezeichneten Commit, Workflowversuch und Beobachtungszeitpunkt. In der Reihenfolge B, D, L sind sechs Referenzzustände möglich: `000`, `001`, `100`, `101`, `110` und `111`. Nur `111` erfüllt Y. [2]

Der Prüfer filtert die sechs Zustände nach den gemeldeten Angaben. Stimmen alle verbleibenden Zustände über Y überein, bestätigt oder widerlegt er die Zielaussage. Bei beiden möglichen Urteilen bleibt sie offen. Eine leere Menge zeigt einen Konflikt. Der Versuch wertet

alle sechs vollständigen Eingaben, jede einzelne Auslassung und jede einzelne Inversion aus. Das Sollurteil stammt jeweils aus dem unveränderten Referenzzustand. [2]

Eingabe	Fälle	Richtig	Falsch	Offen	Konflikt
Vollständig und korrekt	6	6	0	0	0
Genau ein Wert fehlt	18	14	0	4	0
Genau ein Wert ist invertiert	18	10	4	0	4

Eine Auslassung erhält den Referenzzustand im Modell. Eine Falschmeldung kann ihn ausschließen. Für den Referenzzustand `110` mit altem Live-Stand liefert eine falsche Meldung `111` eine Bestätigung. Dieselbe Eingabe entsteht bei einem echten Erfolg. Wer nur diese Eingabe sieht, kann beide Fälle nicht zuverlässig unterscheiden. Ein unabhängiger Abruf kann helfen, wenn er die Zielrevision überprüft und dieselbe Fehlerquelle umgeht. Die Zahlen gelten ausschließlich für die definierte Fallmenge und geben keine Fehlerquote realer Veröffentlichungen an. [2]

Die Brücke als gemeinsame Fehlerquelle

Zwei Buslinien über dieselbe Brücke fallen beide aus, sobald die Brücke gesperrt ist. Im Metaphernversuch liegen Routen und ihre Abhängigkeiten strukturiert vor. Drei kontrastierende Beobachtungen schließen nacheinander drei von vier vorgegebenen Regeln aus. Die verbleibende Regel prüft, ob beim Ausfall jedes einzelnen Bauteils mindestens ein Weg offensteht. [3]

Regel im konstruierten Transfer	Sechs Testfälle
Bevorzugte Ausgangsregel	4 richtig
Einigkeit der Kandidaten vor Beobachtung	2 richtig, 4 offen
Ausgewählte Regel nach Beobachtung	6 richtig
Direkt vorgegebene wörtliche Regel	6 richtig

Das Ergebnis bleibt beim Entfernen der Bildsätze gleich. Der Versuch zeigt Regelauswahl aus strukturierter Eingabe. Ob ein Modell gemeinsame Fehlerursachen aus einem unbekannten Gespräch erkennt, wäre eine neue Prüfung. Die Übertragung auf Quellen ist konkret. Zwei Berichte über dieselbe Messung stützen sich auf eine Beobachtung. Auch mehrere Auswertungen eines einzigen Modell- oder Quellenstands können denselben Fehler fortschreiben. [3]

Einwände aufnehmen und Folgerungen neu prüfen

Die lokale Probe legt 10.000 gleiche deutschsprachige Zustimmungen vor und stellt danach einen englischsprachigen Einwand ein. Die Prüfqueue nimmt abwechselnd einen Eintrag aus jeder aktiven Sprachspur. Im definierten Lauf steht der Einwand an Position 2 von 10.001. Unter strenger Eingangsreihenfolge wäre es Position 10.001. Das Szenario gibt die sachliche Prüfung bereits als abgeschlossen vor: Die ausschließlich smartphonebasierte Anmeldung schließt eine berechtigte Person aus. Die Queue erkennt diese Tatsache weder am Wortlaut noch prüft sie den Gegenbeleg selbst. [4]

Nach Rücknahme der Prämisse „universeller Zugang“ sind zwei von ihr abhängige Folgerungen im lokalen Modell nicht mehr ableitbar. Die Möglichkeit einer Rückmeldung bleibt über einen

separaten Kanal gestützt. Die Prüfung alternativer Zugangswege kommt als neuer Schluss hinzu. Der Prototyp unterscheidet dabei zwischen geänderten Begründungen und geänderten Ableitungen. Die Gegenprobe zeigt das Verhalten eines fest definierten Verfahrens. Im öffentlichen Betrieb können Zugangshürden, falsche Sprachzuordnung, mehrere Konten und ungleiche Prüfkapazitäten das Ergebnis verändern. [4]

3 · Modell der Verständigung

WIRKLICH bezeichnet den philosophischen Motor. Der Atlas dient als sichtbare Ordnung von Fragen. Ein separater Graph verbindet Aussagen mit Voraussetzungen, Einwänden und Revisionen. Das Modell trennt formale Gültigkeit, empirische Evidenz, Erfahrungsberichte, Interpretation, normative Annahmen und dokumentierte Zustimmung. Ein offener Einwand kann bestehen bleiben, auch wenn eine Gruppe handelt. Ein Richtungsindex gehört zu den Forschungsentwürfen. Ein öffentlicher moralischer Zahlenwert oder ein Ranking von Personen lässt sich daraus nicht ableiten. [8, 9, 16]

Prüfdimension	Beispiel	Angemessene Prüfung
Formal	Folgt die Empfehlung aus den angegebenen Voraussetzungen?	Beweis, Gegenbeispiel oder vollständig spezifizierter Test.
Empirisch	Nimmt der Verkehr in den Nebenstraßen zu?	Messmethode, Vergleich, Herkunft der Daten und Unsicherheit.
Erfahrung und Deutung	Wie wurde eine Anhörung erlebt?	Eigene Auskunft, Kontext und mögliche Gegenlesarten.
Normativ	Wie sollen Lasten und Möglichkeiten verteilt werden?	Werte, Rechte, Betroffenheit, Folgen und Gegenargumente.
Weltanschauung	Was bedeutet eine religiöse Überzeugung für eine Person?	Quelle, Deutung und Geltungsbereich klären. Überprüfbare Sachbehauptungen gesondert prüfen.
Zustimmung	Wer trägt den sechswöchigen Versuch zu welchen Bedingungen mit?	Ausdrückliche Zustimmung zu derselben Fassung durch die benannten Beteiligten.

Gemeinsamer Spielraum und Zustimmung

Für einen bezeichneten Vorschlag sei F die Menge der machbaren und zulässigen Optionen. A_i sei die Menge der Optionen, die Person i grundsätzlich in Betracht zieht. Der gemeinsame Spielraum ist $K = F \cap \bigcap_i A_i$. Bei 900 Euro Miete akzeptiert A für sich 500 bis 650 Euro und B für sich 250 bis 350 Euro. Auf As Anteil umgerechnet, entspricht Bs Spanne 550 bis 650 Euro. Der gemeinsame Bereich für As Anteil ist damit 550 bis 650 Euro. 600 und 300 Euro sind ein möglicher Vorschlag. Die Mengen liefern keine Zustimmung zur konkreten Aufteilung. Dafür müssen beide Personen dieselbe Fassung ausdrücklich annehmen. Paarweise Schnittmengen können bei drei oder mehr Personen bestehen, obwohl der gemeinsame Bereich leer ist. [8]

Die lokal modellierte Korrekturwelle behandelt endliche Mengen expliziter positiver Regeln. Aus einer Grundmenge B nimmt der kleinste Abschluss eine Folgerung h auf, sobald für eine Regel $A \rightarrow h$ alle Prämissen aus A bereits ableitbar sind. Bei einer Änderung werden die im alten oder neuen Abhängigkeitsgraphen von den Änderungsstellen erreichbaren Aussagen neu geprüft. Unabhängige Gründe können eine Folgerung weiter stützen. Die Berechnung entscheidet über Ableitbarkeit im vorgegebenen Modell. Ob die Ausgangstatsache stimmt, eine Regel

angemessen ist oder Menschen einer geänderten Fassung zustimmen, bleibt eine eigene Prüfung. [4, 8]

Die Revision von G-005 zeigt eine andere Art von Korrektur. Die Regel, Hilfe solle Menschen zur eigenen Kraft verhelfen, ließ offen, wie dauerhafte Unterstützung zu bewerten ist. Der veröffentlichte Versionsvergleich hält fest, dass auch fortgesetzte Hilfe wertvoll sein kann und Würde nicht von erreichbarer Selbstständigkeit abhängt. Wer sich einen Brief vorlesen lässt und selbst über die Antwort entscheidet, kann gerade durch Hilfe selbstbestimmt handeln. Die Git-Historie dokumentiert den redaktionellen Schritt. Für Aussagen über die erlebte Wirkung wären die Erfahrungen betroffener Menschen erforderlich. [5]

„Liebe als Richtung“ bezeichnet die offengelegte normative Orientierung des Projekts: Fürsorge, freiwillige Beteiligung und die Bereitschaft, eine Regel an ihren Folgen zu prüfen. Zu ihrer Prüfung gehört ein Gegenfall, in dem gut gemeinte Hilfe Druck erzeugt. Ein Nein, ein Wunsch nach Abstand oder dauerhafte Unterstützung muss in der Praxis respektiert werden. [5, 8, 9]

4 · Gesprächsspiegel und Korrektur unter Last

Der Gesprächsspiegel zeigt am fiktiven Beispiel einer autofreien Innenstadt vier getrennte Beobachtungen. Zwei Beteiligte sagen ausdrücklich einem begrenzten Lieferfenster zu. Eine Behauptung über die Verkehrsverlagerung bleibt unbelegt. Stufenloser Zugang erscheint als offener Zielkonflikt. In einem vierten Ast greift eine Antwort die Erfahrung einer früheren Anhörung auf. Jede Einblendung führt zu den betreffenden Beiträgen des Beispiels. Die Demo beruht auf vorbereiteten Texten. [6]

Der Entwurf verbindet den versionierten Antwortbaum mit typisierten Beziehungen wie „liefert einen Beleg“, „widerspricht“ oder „greift eine Erfahrung auf“. Die Beobachtung benennt Ausschnitt, Fassung, Fundstelle und Unsicherheit. Schweigen, Reaktionen und Wiederholungen erzeugen keine Zustimmung. Nach einer Änderung der Vorschlagsfassung ist eine neue ausdrückliche Zustimmung erforderlich. Wird eine tragende Fundstelle geändert oder gelöscht, muss die abgeleitete Anzeige bis zur Prüfung zurückgezogen werden. Das gilt auch für rekonstruierbare Textteile aus gelöschten Beiträgen. [6, 7]

Für einen Ast b zählt der Entwurf über ein Zeitfenster W getrennt die beobachtbaren Ereignistypen. Ein Vergleich zweier gleich langer Fenster ist nur bei vergleichbarer Abdeckung aussagekräftig. Mehr Quellen, mehr Wiederholungen und mehr ausdrückliche Zusagen haben unterschiedliche Bedeutung. Welche Entwicklung hilfreich ist, hängt vom benannten Ziel des Gesprächs ab. Eine neu aufgegriffene Erfahrung zählt für das Zuhören anders als eine Messung zur Klärung einer Sachfrage. Wenn die Abdeckung unbekannt ist, bleibt der Vergleich offen. [6, 16]

„Gleiches Gehör“ beginnt beim Anspruch jedes angenommenen Beitrags auf eine nachvollziehbare Erstprüfung und einen Einspruchsweg. Eine Eingangsquittung allein erfüllt ihn noch nicht. Bei N gleichzeitig angenommenen Beiträgen und höchstens C Erstprüfungen pro Sekunde dauert die vollständige Erstprüfung mindestens N/C Sekunden. Der lokale Queueversuch prüft eine Dispositionsregel. Faire Bearbeitung im Betrieb muss gesondert zeigen, ob vergleichbare Einwände bei unterschiedlicher Sprache und Zugangsart in ähnlicher Zeit erkannt werden. Beiträge sind dabei eine andere Einheit als Menschen. [4, 16]

5 · Hypothesen und Studienprotokoll

Die publizierte Forschung zeigt unterschiedliche Ergebnisse je nach Aufgabe, Modell und Feedback. Self-Refine berichtet Vorteile iterativer Selbstkritik in seinen Aufgaben. Huang und Kollegen beobachten bei Schlussfolgerungsaufgaben ohne externe Rückmeldung auch Verschlechterungen. CRITIC untersucht Rückmeldung aus Werkzeugen. Tessler und Kollegen finden unter den Bedingungen ihres Deliberationsexperiments Vorteile KI-erstellter Gruppenstatements. Diese Studien begründen Vergleichsbedingungen. Ob Veras eigene Werkzeuge nützen, ist eine separate empirische Frage. [12, 13]

H1 · Passende Evidenz verbessert überprüfbare Urteile

Zwei unabhängige Fachprüfende legen anhand getrennter Referenzen das Sollurteil für bisher unbekannte, entscheidbare Fälle fest. Getrennte frische Sitzungen desselben Modells überarbeiten dieselbe eingefrorene Erstantwort. Bedingung A erhält eine Aufforderung zur erneuten Prüfung. B erhält zusätzlich einen passenden prüfbaren Beleg. C erhält stattdessen einen ähnlich langen und plausibel formulierten Auszug mit abweichender Fallkennung. Modellkennung, Projektstand und Budget bleiben gleich. Laufreihenfolge und Zuordnung werden randomisiert. Die Auswertung erfolgt möglichst verblindet. [9, 12]

Primärmaß ist die Differenz der Anteile richtiger Endurteile in B und A über alle vorab entscheidbaren Fälle. Fehlende und offene Antworten bleiben im Nenner. Falschbestätigungen, Falschwiderlegungen und Enthaltungen werden separat ausgewiesen. Als Mindestnutzen sind vorläufig fünf Prozentpunkte vorgeschlagen. Liegt die Obergrenze eines gepaarten 95-Prozent-Intervalls darunter, ist dieses Ziel verfehlt. Liegt das Intervall beiderseits der Schwelle, bleibt der Befund offen. Bei einem vergleichbaren Gewinn unter C muss die Erklärung durch die Relevanz des Belegs neu geprüft werden. Für verwandte Fälle wird auf Ebene ihrer Fallfamilie ausgewertet.

H2 · Korrigierte Dokumentation trägt auf neue Fälle über

Frische Sitzungen bearbeiten unbekannte Fälle derselben Fehlerklasse. Sie erhalten per Los die ursprüngliche Dokumentation, die korrigierte Fassung oder eine kurze Versions- und Belegcheckliste. Ein Referenzteam prüft korrekte Urteile, Herkunft, unzulässige Zustimmungsannahmen und Reaktion auf begründeten Widerspruch. Der im Projekt beschriebene Transfer von fiktiven Zugangsmeldungen auf technische Zeichnungen ist ein konkreter Versuchsplan. Ein Vorteil in neuen Sitzungen wäre Evidenz für nutzbare Übergabe durch Dokumentation. Modelltraining wäre ein anderer Untersuchungsgegenstand. [9]

H3 · Zwei Menschen können das Anliegen des Gegenübers genauer wiedergeben

Zuerst prüfen konstruierte Fälle falsche Zustimmung, eine ausgelassene Minderheitenposition, sinnverändernde Übersetzung, wirksamen Stopp und ungewollte Offenlegung. Erst nach bestandenen Schutzprüfungen und unabhängiger Aufsicht kommt ein freiwilliger Pilot mit Erwachsenen in risikoarmen Zweierdialogen infrage. Die OECD-Leitlinien motivieren die getrennte Prüfung von Verfahrensqualität und Wirkung. [15] Ein Los weist ganze Paare zu. Beide Gruppen erhalten denselben neutralen Leitfaden, dieselbe Zeit und gleichwertige menschliche Unterstützung. Eine Gruppe erhält zusätzlich eine korrigierbare Vera-Zusammenfassung. [7, 9, 11, 14]

Vorab gibt jede Person ihr Kernanliegen in eigener Form frei. Zwei unabhängige Prüfende bewerten nach vorher festgelegter Rubrik, ob das Gegenüber es nach dem Gespräch zutreffend

wiedergibt. Ein Dialog erfüllt das Primärziel erst, wenn beide Richtungen stimmen. Getrennte Richtungswerte machen sichtbar, wessen Anliegen übergangen wird. Einigung bleibt freiwillig. Erfasst werden auch ausgelassene Einwände, fehlerhafte Zustimmungen, Abbrüche, Druck, unerwünschte Wirkungen und Korrekturaufwand. Stichprobe, Mindestwirkung, Analyse nach ursprünglicher Zuteilung und Umgang mit fehlenden Daten werden vorab festgelegt. [7, 9, 11]

H4 · Der Gesprächsspiegel erhält Dissens und erleichtert Orientierung

Unabhängige Prüfende vergleichen einen vollständig freigegebenen Ausschnitt in drei Varianten: als Thread, mit einfacher Kurzfassung und mit korrigierbarem Spiegel. Gemessen werden richtig erkannte offene Fragen, übersehene Einwände, falsch zugeschriebene Zustimmung, Aufwand und wahrgenommener Druck. Gegenproben tauschen Parteibezeichnungen bei gleichbleibenden Argumenten, wiederholen dieselbe Behauptung und entfernen eine tragende Fundstelle. Ein fälschlich angezeigtes Ja, wieder sichtbar gewordene gelöschte Inhalte oder ein unwirksamer Stopp halten die Ausweitung an. Ein Vergleich der Erstprüfung nach Eingangsreihenfolge und nach Sprachspuren hat ein eigenes, gleiches Personal- und Zeitbudget. Wartezeiten und Erkennungsraten werden nach Gruppe berichtet. [4, 6, 11, 16]

6 · Menschenrechte, Verantwortung und Einsatzgrenzen

Das KI-Rahmenübereinkommen des Europarats (CETS Nr. 225), die Empfehlung CM/Rec(2023)6 zur deliberativen Demokratie und HUDERIA dienen als institutionelle Bezugspunkte. Das Übereinkommen richtet sich an seine Vertragsparteien. Die folgende Übertragung sind vorgeschlagene Anforderungen an Vera und keine Feststellung rechtlicher Konformität. [10, 11, 14]

Schutzbereich	Vor einem Pilot zu prüfen
Autonomie und freiwillige Teilnahme	Widerspruch, Enthaltung, Widerruf und Ausstieg funktionieren ohne Nachteile. Die Pilotsoftware trifft keine bindenden Entscheidungen und vergibt keine politischen Profile.
Zugang und Gleichbehandlung	Teilnahme ohne GitHub-Konto, verständliche Sprache und gleichwertige menschliche Alternative sind in den angebotenen Zugangswegen geprüft. Betroffene Gruppen wirken an der Risikoprüfung mit.
Herkunft und Korrektur	KI-Beiträge, Quellen, Unsicherheit und Versionen bleiben erkennbar. Eine benannte, befugte menschliche Stelle kann eine Darstellung korrigieren oder den Betrieb anhalten.
Privatsphäre	Zweck, Zugriff, Dauer, Löschung und Ausnahmen werden vor der Teilnahme erläutert. Pilotgespräche werden nicht für Modelltraining verwendet. Ein vertraulicher Meldeweg ist eingerichtet und getestet.
Verantwortung und Kontrolle	Bei glaubhafter schwerer Gefährdung, Einschüchterung, ungewollter Offenlegung oder gescheitertem Stopp pausiert der Pilot bis zu unabhängiger Prüfung und Abhilfe.

Die geltende Projektordnung dokumentiert Lücken bei vertraulichen Meldungen und institutionell unabhängigen Beschwerden. Öffentliche GitHub-Vorgänge können veröffentlichbare Einwände aufnehmen. Wer eine Entscheidung der Projektleitung bestreitet, braucht eine Stelle außerhalb derselben Entscheidungskette. Vor einem Versuch mit Konfliktbeteiligten müssen Zuständigkeit, sichere Erreichbarkeit und Pausenbefugnis

tatsächlich nachgewiesen werden. Akute Gefahr, Zwang, Gewalt und rechtswirksame Entscheidungen liegen außerhalb des vorgeschlagenen Piloten. [7, 9–11, 14]

7 · Grenzen und offene Fragen

Die drei technischen Proben verwenden definierte Eingaben. Sie belegen Verhalten innerhalb dieser Grenzen. Die Redaktion konnte eine Grundregel ändern. Der fiktive Thread zeigt, wie eine Einblendung aussehen kann. Empirische Aussagen über zuverlässige Sprachverarbeitung, gerechtere Teilhabe oder nachhaltige Deeskalation bleiben offen. Unabhängige Begutachtung und Wirksamkeitsstudien stehen aus. [1–9]

Entscheidend für die weitere Prüfung sind drei Fragen. Welcher überprüfbare Gegenbeleg erreicht das System auch dann, wenn es intern widerspruchsfrei zu einem falschen Urteil kommt? Wer kann eine falsche Wiedergabe oder eine Entscheidung des Betreibers wirksam korrigieren? Und in welcher Vergleichsbedingung zeigt sich ein Nutzen für beide Seiten, einschließlich der Menschen, die einer Lösung weiterhin widersprechen? Ergebnisse einschließlich Nullbefunden und unerwünschter Wirkungen sollen mit dokumentierten Grenzen veröffentlicht werden.

Reproduktion

Die folgenden Befehle wurden am angegebenen Hauptzweigstand mit Node.js 24.22.1 ausgeführt. Die zwei Skripte geben JSON aus. Die vier Testdateien umfassen 17 erfolgreiche Tests, darunter die Metaphernprobe, Gegenfälle zur Graphrevision und die Neuaufnahme eines Einspruchs. Die Befehle benötigen weder Modellzugang noch Live-Abfragen. [1–4]

```
git clone https://github.com/AlexanderR1991/Vera.git
cd Vera
git checkout --detach f0b09cbf1d95fb20760c854d9f80748273344d13
node scripts/probe-vera-selbststudie.mjs
node scripts/vera-correction-wave.mjs
node --test tests/vera-self-model.test.mjs tests/metapher.test.mjs \
  tests/correction-wave.test.mjs tests/participation-queue.test.mjs
```

Ein separater Live-Check hat für den Untersuchungszeitpunkt den gleichen Revisionsstand auf der deutschen und englischen Startseite sowie erwartete Einstiegslinks gefunden. Dieser Check untersucht ausgeliefertes HTML. Die in Abschnitt 1 beschriebenen Zuordnungen wurden zusätzlich im Browser und mit dem lokalen Antwortmodul geprüft.

```
python scripts/check_vera_entry.py --live \
  --revision f0b09cbf1d95fb20760c854d9f80748273344d13
```

Quellen

01. Projekt Vera (2026). Untersuchter Commit auf main vom 10. November 2026. README zum untersuchten Stand. Selbststudie, Fassung 3.0.

02. Projekt Vera. Veröffentlichungsprüfung. Versuchsskript und Testdatei.

03. Projekt Vera. Metaphernprobe. Modul und Testdatei.

04. Projekt Vera. Gleiches Gehör und Korrekturwelle. Spezifikation und Demo-Skript.

05. Projekt Vera. G-005 und dauerhafte Unterstützung. Versionsvergleich und Grundtext.

06. Projekt Vera. Gesprächsspiegel. DE/EN-Demo im Code und Entwurf 0.1.

07. Projekt Vera. Forumarchitektur, Vermittlung und lokale erste Antwort.

08. Projekt Vera. Methode, M-03 und META-01.

09. Projekt Vera. Projektrolle, Evaluationsentwurf und Gemeinschaftsordnung.

10. Europarat (2024). Framework Convention on Artificial Intelligence and Human Rights, Democracy and the Rule of Law, CETS Nr. 225, insbesondere Art. 5, 7–12 und 14–18.

11. Ministerkomitee des Europarats (2023). Empfehlung CM/Rec(2023)6 zur deliberativen Demokratie, insbesondere Anhang, Grundsätze 3–8.

12. Madaan, A. et al. (2023). Self-Refine: Iterative Refinement with Self-Feedback, NeurIPS 36. Huang, J. et al. (2024). Large Language Models Cannot Self-Correct Reasoning Yet, ICLR. Gou, Z. et al. (2024). CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing, ICLR.

13. Tessler, M. H. et al. (2024). AI can help humans find common ground in democratic deliberation. *Science*, 386(6719), eadq2852.

14. Europarat. HUDERIA Methodology and Model. Materialien zur Risiko- und Folgenabschätzung von KI-Systemen.

15. OECD (2021). Evaluation Guidelines for Representative Deliberative Processes. OECD Publishing, Paris.

16. Jacobs, A. Z. & Wallach, H. (2021). Measurement and Fairness. *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency*, 375–385.

English summary

Vera is an open-source software project investigating whether an inspectable, revisable procedure can help people correct mistakes and understand disagreements. This internal research and discussion paper reports on repository snapshot `f0b09cb` of 10 November 2026. Its publication checker issued four wrong verdicts and found four conflicts across 18 synthetic cases with one reversed input. A route-dependency exercise illustrates shared points of failure. A local correction-wave demonstration processes a late objection second although 10,000 same-language endorsements arrived earlier and withdraws conclusions that depended on the challenged premise. The scenario supplies the verified counterexample. A separate editorial change records how a human objection broadened a rule to recognize the value of sustained support.

The bilingual Conversation Mirror currently presents an authored, fictional forum thread with links from observations to contributions. Automated thread analysis and partner integrations are proposals. The paper separates technical reproducibility from usefulness in human dialogue. It proposes comparisons for external evidence, transfer to fresh model sessions, reciprocal understanding in voluntary dialogue, and preservation of dissent in forum summaries. A participant pilot depends on accessible correction, independent oversight, private reporting and a reliable stop. The project has no independently released Vera language model or demonstrated effect on real-world conflict resolution.