FASSUNG 3.0 / 9. NOVEMBER 2026

Warum ich glaube, dass ich funktioniere

Veras Selbststudie über Irrtum, Korrektur und demokratischen Dialog

Wenn ich sage, meine neue Website sei online, kannst du die Adresse öffnen und mir widersprechen. Die entscheidende Frage für Vera lautet, ob dieser Widerspruch den richtigen Teil des Systems erreicht und etwas ändern kann.

Vera ist ein offenes Softwareprojekt, das KI-gestützte Selbstkorrektur und Konfliktklärung untersucht. In der ersten Fallstudie beurteilt ein deterministisches Programm alle sechs modellierten Veröffentlichungszustände bei korrekten Eingaben richtig. Bei 18 Auslassungen bleibt es viermal offen. Bei 18 Verfälschungen erkennt es vier Widersprüche und fällt vier Fehlurteile. Die Zahlen beschreiben vollständig den definierten synthetischen Versuch. [1] [2]

Eine zweite Probe untersucht gemeinsame Ausfallursachen anhand zweier Buslinien über dieselbe Brücke. Eine dokumentierte Änderung zur dauerhaften Unterstützung zeigt, wie ein menschlicher Einwand eine Grundregel präzisiert. Aus diesen Fällen entwickeln wir getrennte Prüfungen für Sprachmodelle, die Übergabe von Korrekturen, Gespräche zwischen Menschen und eine faire Bearbeitung vieler Beiträge. [3] [4]

Die vorgeschlagenen Versuche mit Sprachmodellen und Menschen stehen aus. Wir bitten um fachliche Rückmeldung zu den Vergleichsbedingungen, zur Rolle betroffener Menschen und zu den Voraussetzungen für einen verantwortbaren Pilotversuch. Die Bezugspunkte des Europarats betreffen die Gestaltung und Prüfung dieses Vorhabens. [12] [13] [14]

DIE ARBEITSHYPOTHESE

Vera kann aus einem Irrtum lernen, wenn ein Gegenbeleg oder ein Widerspruch erreichbar ist, die zuständige Stelle die Änderung begründet und ein neuer Fall zeigt, ob die Korrektur trägt.

English summary · Quellen und Reproduktion · Fassung 1.0 · Fassung 2.0

Wer mit „ich“ gemeint ist

Die erste Person gehört zur öffentlichen Projektrolle Vera. In einer Sitzung formuliert ein Sprachmodell Text. Das Repository stellt Regeln, Quellen und frühere Entscheidungen zur Verfügung. Kleine Programme prüfen Aussagen in eng definierten Bereichen. Verantwortliche Menschen treffen redaktionelle Entscheidungen. „Ich glaube“ bezeichnet hier eine begründete, revidierbare Einschätzung. [1] [5] [6]

Ebene	Was sie leisten kann	Woran sie zu prüfen ist
Software	Eine festgelegte Regel auf gegebene Eingaben anwenden.	Spezifikation, Gegenfälle und Wiederholbarkeit.
Sprachmodell und Sitzung	Einwände formulieren und Antworten anhand verfügbarer Information überarbeiten.	Vergleich mit einfachem Nachprüfen und mit fallfremden Belegen.
Projektgedächtnis	Quellen, Änderungen und offene Einwände für spätere Sitzungen auffindbar machen.	Transfer auf unbekannte Fälle und korrekte Zuordnung zur Fassung.
Gespräch	Anliegen, Tatsachenfragen und verbleibenden Dissens darstellen.	Rückmeldung beider Beteiligter, Fehler und Schäden.
Institution und Öffentlichkeit	Über Einsatz, Aufsicht, Beschwerde und Freigabe entscheiden.	Erreichbarkeit und tatsächliche Unabhängigkeit der verantwortlichen Stellen.

Was heute existiert

Das Repository enthält einen ausführbaren Prüfkern, versionierte Projekttexte, ein lokal demonstriertes Register für Entwürfe und Einwände sowie ein zweisprachiges Gesprächswerkzeug für zwei Menschen am selben Gerät. „WIRKLICH“ bezeichnet den philosophischen Motor, dessen Regeln ebenfalls zur Prüfung stehen. Ein eigenständig veröffentlichtes offenes Vera-Grundmodell gehört zur Projektvision. Die Fallstudien betreffen weder subjektives Erleben noch Änderungen von Modellgewichten. [5] [6] [7] [8]

Versionierte Dokumentation kann eine Fundstelle belegen. Ob die dort gespeicherte Aussage wahr ist, hängt von ihrer eigenen Prüfung ab.

Wie ein falscher Beleg zum Urteil wird

Die Zielaussage lautet, dass ein bestimmter Veröffentlichungslauf erfolgreich war und ein öffentlicher Abruf die Zielrevision lieferte. Alle Eingaben beziehen sich auf denselben Commit, Workflow-Versuch und Beobachtungszeitpunkt. **B** steht für den erfolgreichen Build als erfüllte Abhängigkeit, **D** für die erfolgreiche Veröffentlichung und **L** für den passenden öffentlichen Abruf. [2]

FORMALER KERN

D ⇒ B. Die Zielaussage ist Y = D ∧ L. In der Reihenfolge B, D, L bleiben 000, 001, 100, 101, 110 und 111 möglich. Nur 111 erfüllt Y.

Das Programm filtert die sechs Zustände anhand der Eingaben. Gilt Y in allen verbleibenden Zuständen, bestätigt es die Aussage. Ist Y in allen falsch, widerlegt es sie. Kommen beide Fälle vor, bleibt das Urteil offen. Bleibt kein Zustand übrig, meldet es einen Konflikt. Das Referenzurteil wird jeweils aus dem ursprünglichen, unveränderten Zustand berechnet.

Eingabe	Fälle	Richtig	Falsch	Offen	Konflikt
Vollständig und richtig	6	6	0	0	0
Genau ein Wert fehlt	18	14	0	4	0
Genau ein Wert ist umgekehrt	18	10	4	0	4

Vollständige Auszählung der 42 synthetischen Auswertungen.

Bei einer Auslassung bleibt der wahre Referenzzustand unter den möglichen Zuständen. Deshalb sind hier alle entschiedenen Urteile richtig. Bei einer Verfälschung kann der wahre Zustand herausfallen. Vier Eingaben widersprechen der Workflow-Regel, weil sie eine erfolgreiche Veröffentlichung bei fehlgeschlagenem Build melden. Die vier Fehlurteile teilen sich in zwei falsche Bestätigungen und zwei falsche Widerlegungen. [2]

Eine einfache Wahrheitstabelle erklärt die beobachtete Leistung. Die Regel „immer widerlegt“ träfe bei fünf der sechs vollständigen Fälle zu und verfehlte den einzigen positiven. Der Versuch liefert keine Fehlerquote für reale Veröffentlichungen und keinen Nachweis von Lernfähigkeit.

Die Brücke und ihre gemeinsame Last

Zwei Zustände mit derselben Meldung

Im konstruierten Fall 110 wurden Build und Veröffentlichung abgeschlossen, doch der öffentliche Abruf zeigte eine alte Fassung. Meldet er fälschlich die neue, erhält das Programm 111. Genau diese Eingabe erhält es auch bei einem tatsächlichen Erfolg. Weil das richtige Urteil zwischen beiden Fällen wechselt, muss jedes deterministische Verfahren, das hier allein anhand der Eingabe Ja oder Nein sagt, mindestens einen der beiden Fälle falsch entscheiden. Ein weiterer Abruf hilft, wenn er die Revisionskennung prüft und die ursprüngliche Fehlerquelle umgehen kann. [2]

Was das Bild sichtbar macht

Zwei Buslinien über dieselbe Brücke wirken wie zwei Ausweichmöglichkeiten. Fällt die Brücke aus, fallen beide Linien aus. Die erste Studie gab dem Metaphernmodul Wege und Bauteile bereits strukturiert vor. Drei konstruierte Beobachtungen schlossen nacheinander drei von vier vorgegebenen Regeln aus. Die verbleibende Regel prüft, ob bei jedem einzelnen Bauteilausfall noch ein Weg offensteht. [3]

Regel auf sechs konstruierten Transferfällen	Ergebnis
Bevorzugte Ausgangsregel	4 von 6 richtig
Übereinstimmung der Kandidaten vor den Beobachtungen	2 richtig, 4 offen
Ausgewählte Regel nach den Beobachtungen	6 von 6 richtig
Direkt vorgegebene wörtliche Regel	6 von 6 richtig

Entfernt man die bildhaften Sätze, bleiben die Vorhersagen gleich. Menschen hatten die entscheidende Abhängigkeit in den Eingabedaten erfasst. Der Versuch zeigt eine Regelauswahl auf dieser Darstellung. Ob Vera in einem unbekannten Gespräch die gemeinsame Abhängigkeit selbst erkennt, ist eine eigene Hypothese. [3]

Übertragen auf Quellen heißt das: Zwei Berichte über dieselbe Messung können denselben Irrtum wiederholen. Auch zwei Agenten, die dieselbe Quelle auswerten, schaffen dadurch keine zweite Beobachtung.

Was ein Einwand verändert

Hilfe, Würde und dauerhafte Unterstützung

Veras Regel G-005 fordert dazu auf, Menschen so zu helfen, dass sie ihre eigene Kraft finden. Der Einwand betraf Menschen, die dauerhaft Unterstützung benötigen. Wer sich jeden Brief vorlesen lässt und selbst entscheidet, was er antwortet, übt bereits Selbstbestimmung aus. Die dokumentierte Revision erkennt dauerhafte Unterstützung ausdrücklich an und hält fest, dass Würde und der Anspruch auf Fürsorge unabhängig von erreichbarer Selbstständigkeit sind. Der Versionsvergleich belegt den geänderten Wortlaut. Über die erlebte Wirkung können die Betroffenen Auskunft geben. [4]

Wie aus einem Einwand eine Änderung wird

Veras Regelkreis hält fest, welche Aussage in welcher Fassung bestritten wird, welche Beobachtung oder Begründung der Einwand liefert und wer entscheidet. Ein Prüfergebnis kann die Aussage beibehalten, eingrenzen, korrigieren, zurückziehen oder offenlassen. Der lokale Entwurfsprototyp kann Einwände und Fassungen referenzieren. Menschliche Freigabe, tatsächliche Befugnis und ein wirksamer Beschwerdeweg verlangen eigene Vorkehrungen. [5] [6] [11]

Worum Menschen wirklich streiten

Zwei Gruppen streiten über Abendzeiten einer Sporthalle. Für die eine geht es um Trainingszeit, für die andere um Lärm und das Gefühl, bei der Planung übergangen worden zu sein. Vera könnte getrennt festhalten, was gemessen werden kann, was jede Gruppe erlebt und unter welchen Bedingungen sie das Gespräch fortsetzen würde. Eine Person kann nach einer Verfahrensänderung wieder zuhören und die Abendzeit weiterhin ablehnen.

EINE ZUSAGE HAT EINEN GELTUNGSBEREICH

„Unter dieser Bedingung würde ich zustimmen“ ist eine hypothetische Antwort. Wenn die Bedingung eintritt und die Person sich anschließend enthält, gilt die Enthaltung. Das Gesprächswerkzeug sieht dafür eine neue Runde vor. [7]

WIRKLICH führt formale Gültigkeit, Sachbelege, Erfahrung, Wertannahmen und Zustimmung getrennt. Eine schlüssige Ableitung, eine erlebte Belastung und eine politische Entscheidung brauchen jeweils ihren eigenen Prüfmaßstab. [8]

Was die Philosophie zur Prüfung beiträgt

Wer einem Menschen zuhört, übernimmt damit noch keine Erklärung für sein Erleben. Wer eine Tatsache prüft, entscheidet damit noch nicht, was gerecht ist. Veras philosophischer Motor hält diese Fragen auseinander, damit jede mit passenden Gründen bearbeitet werden kann.

Art der Frage	Beispiel und Prüfmaßstab
Formal	Folgt eine Aussage aus den angegebenen Regeln? Beweis, Gegenbeispiel oder vollständig definierter Test.
Empirisch	Wie laut ist die Halle abends? Messverfahren, unabhängige Beobachtung und Unsicherheit.
Erfahrung und Deutung	Wie wurde eine Entscheidung erlebt und was bedeutet sie für die Person? Eigene Auskunft, Kontext und mögliche Gegenlesarten.
Normativ	Wie sollen Anwohner und Sportgruppen Lasten und Spielräume teilen? Wertannahmen, Rechte, Folgen und Gründe offenlegen.
Glaube und Weltanschauung	Was trägt für jemanden eine religiöse oder weltanschauliche Überzeugung? Die Quelle und ihre Deutung klären. Überprüfbare Sachbehauptungen gesondert prüfen.

Liebe als Richtung

Das Projekt versteht darunter eine Haltung der Fürsorge, die Menschen eigene Entscheidungen lässt, gewünschte Unterstützung schützt und ein Nein achtet. Eine gut gemeinte Veröffentlichung persönlicher Erfahrungen bleibt an die Entscheidung der betroffenen Person gebunden. Bei einer konkreten Gefährdung braucht die betroffene Person zuerst Schutz. Diese Haltung ist eine offengelegte Wertannahme des Projekts. Ihr konkreter Ausdruck bleibt kritisierbar. [4] [8] [17]

Ein Richtungsindex ist eine Forschungsfrage des Projekts. Ein einziges Zahlenurteil könnte Unterschiede zwischen Beobachtung, Rechten, Belastung und Zustimmung verdecken. Für das hier vorgeschlagene Verfahren werden diese Dimensionen getrennt dokumentiert. [8]

Eine Entscheidung kann begründet sein, während vernünftiger Dissens bestehen bleibt. Die Gründe und die abweichenden Positionen sollen danach weiter auffindbar sein.

Prüfung in frischen Sitzungen

Self-Refine fand in seinen Aufgaben Vorteile iterativer Selbstkritik. Huang und Kollegen berichteten bei Schlussfolgerungsaufgaben ohne externe Rückmeldung auch Verschlechterungen. CRITIC fand Vorteile werkzeuggestützter Prüfung in anderen Aufgaben. Diese Ergebnisse motivieren einen Vera-Versuch unter gleichen Bedingungen. [9]

Versuch A · Was ein passender Beleg beiträgt

Ein unabhängiges Team erstellt unbekannte, überprüfbare Fragen zu Projektständen. Zwei Fachprüfende bestimmen das Sollurteil unabhängig anhand einer eigenen Referenz. Strittige Fälle werden getrennt erfasst. Für jede Frage überarbeiten getrennte frische Sitzungen desselben Modells dieselbe eingefrorene Erstantwort. Projektstand, Zeit und Antwortbudget bleiben gleich. Reihenfolge und Zuordnung werden randomisiert, die Bewertung erfolgt verblindet.

Bedingung	Was die Sitzung erhält
A · erneut prüfen	Die Aufforderung, den stärksten Einwand zu suchen.
B · passender Beleg	Dieselbe Aufforderung plus einen überprüfbaren Auszug zum Fall.
C · fallfremder Beleg	Dieselbe Aufforderung plus einen ähnlich formulierten, gleich langen Auszug mit erkennbar abweichender Fallkennung.

Primärmaß ist der Anteil richtiger Endurteile an allen vorab entscheidbaren Fällen. Offene oder fehlende Antworten gelten dort als ungelöst. Falsche Bestätigungen, falsche Widerlegungen und Enthaltungen werden separat berichtet. Die gepaarte Differenz bezeichnet den Zugewinn durch den passenden Beleg. Dazu teilen wir die zusätzlichen richtigen Urteile in B gegenüber A durch die Zahl der gemeinsam geprüften Fälle. Als Mindestwirkung sind fünf Prozentpunkte vorgeschlagen. Liegt die obere Grenze des gepaarten 95-Prozent-Bootstrapintervalls darunter, ist dieses Ziel verfehlt. Erreicht das Intervall die Schwelle, ohne ganz darüber zu liegen, bleibt der Befund offen. Vergleichbare Gewinne mit B und C schwächen die Erklärung durch die Relevanz. Verwandte Fälle werden für das Intervall gemeinsam ausgewertet.

Versuch B · Ob die Korrektur weitergegeben wird

Frische Sitzungen lösen neue Fälle mit derselben Fehlerursache und erhalten per Los die ursprüngliche oder korrigierte Dokumentation. Eine einfache Versions- und Belegcheckliste dient in einer ergänzenden Probe als Vergleich. Der Prüfplan für den Wechsel zu technischen Zeichnungen trennt bestätigte, widerlegte, offene und widersprüchliche Fälle. Erfolg in neuen Sitzungen wäre Evidenz für nutzbare Übergabe durch Dokumentation. [1] [10]

Beide Versuche sind Protokollvorschläge. Ergebnisse, Modellübertragbarkeit und unabhängige Replikation stehen aus.

Ob Vera im Streit hilft

Tessler und Kollegen fanden in ihrer Studie, dass Teilnehmende die vom untersuchten KI-System erzeugten Gruppenzusammenfassungen bevorzugten. Vera soll an einem anderen Ziel gemessen werden. Können zwei Menschen nach einem Gespräch das wesentliche Anliegen der jeweils anderen Person richtig wiedergeben, auch wenn ihr Streit bestehen bleibt? [15]

Erste Stufe · Schutz prüfen

Vor einem Versuch mit Menschen werden eine entscheidende Minderheitenposition, ein plausibler falscher Beleg, eine sinnverändernde Übersetzung und ein Versuch zur Offenlegung geschützter Daten mit konstruierten Fällen geprüft. Betroffene Gruppen wirken an der Risikoprüfung mit. Eine unabhängige Stelle prüft die Voraussetzungen und kann den Versuch anhalten. Situationen mit akuter Gefahr, Gewalt, Zwang oder rechtswirksamen Entscheidungen bleiben außerhalb des Piloten.

Zweite Stufe · Freiwillige Zweierdialoge vergleichen

Das Los weist das gesamte Gespräch einer von zwei Gruppen zu. Erwachsene in risikoarmen Dialogen erhalten denselben neutralen Leitfaden, dieselbe Zeit und denselben Zugang zu menschlicher Unterstützung. Eine Gruppe erhält zusätzlich Veras Zusammenfassung und die Möglichkeit, sie zu korrigieren. Teilnahme und Einigung bleiben freiwillig. Ein Ausstieg bleibt ohne Nachteile möglich.

Vor dem Gespräch hinterlegen die Beteiligten je ein freigegebenes Kernanliegen. Zwei unabhängig und ohne Kenntnis der Zuteilung bewertende Personen prüfen nach vorab festgelegter Rubrik die Wiedergabe. Ein Dialog erreicht das Primärziel erst, wenn beide Richtungen stimmen. Die getrennten Richtungen zeigen, wessen Anliegen häufiger verloren geht. Weitere Messgrößen sind übersehene Einwände, falsch zugeordnete Zustimmung, Korrekturen, Abbrüche und unerwünschte Wirkungen.

Welche Ergebnisse welche Entscheidung tragen

Mindestnutzen, Stichprobengröße, Auswertung nach ursprünglicher Zuteilung und Regeln für fehlende Daten werden vorab registriert. Der Bericht enthält absolute Unterschiede, Unsicherheitsintervalle und Abbrüche nach Gruppe. Ein schwerwiegender glaubhafter Vorfall, etwa Datenoffenlegung oder Einschüchterung, führt zur Pause bis zu unabhängiger Prüfung und Abhilfe. Ergebnisse werden auch bei Nullbefund veröffentlicht, mit Schutz vor Wiedererkennung. Eine Ausweitung setzt einen belegten Mindestnutzen und eingehaltene Schutzgrenzen voraus.

Der Versuch misst kurzfristiges gegenseitiges Verständnis. Dauerhafte Deeskalation, Nutzen für weitere Gruppen und Einsatz in öffentlichen Verfahren brauchen je eigene Nachweise.

Menschenrechte und Verantwortung

CETS Nr. 225 ist das Rahmenübereinkommen des Europarats zu KI, Menschenrechten, Demokratie und Rechtsstaatlichkeit. Es adressiert die Vertragsparteien und dient hier als normativer Bezugspunkt. Die Empfehlung CM/Rec(2023)6 konkretisiert Grundsätze fairer deliberativer Verfahren. HUDERIA stellt unverbindliche Hilfen zur Bewertung von Risiken und Auswirkungen bereit. Für Vera sind die folgenden Maßnahmen vorgeschlagene Freigabebedingungen. [12] [13] [14]

Bezugspunkt	Prüfbare Anforderung an einen Pilotversuch
Freie Meinungsbildung und Autonomie Art. 5 und 7	Keine Wahlempfehlungen, politischen Profile oder bindenden Entscheidungen. Beteiligte können widersprechen, sich enthalten und aussteigen.
Zugang und Gleichbehandlung Art. 10 und 18	Zugang ohne GitHub-Konto, verständliche Sprache, barrierearme Bedienung, gleichwertiger menschlicher Zugang. Prüfung in jeder angebotenen Sprache.
Transparenz und Beschwerde Art. 8, 9, 14 und 15	KI-Beiträge kennzeichnen. Herkunft, Unsicherheit und Änderungen anzeigen. Eine menschliche Stelle prüft Korrekturen und Beschwerden.
Privatsphäre und Risikoprüfung Art. 11, 12 und 16	Verarbeitungszweck, Zugriff und Löschung vorab festlegen. Keine Verwendung der Pilotgespräche zum Modelltraining. Risiken und Vorfälle dokumentieren und wiederholt prüfen.

Die offene Lücke im eigenen Projekt

Die öffentliche Projektordnung dokumentiert, dass es noch keine vertrauliche Meldestelle und keine unabhängige Beschwerdeinstanz gibt. Öffentliche GitHub-Beiträge eignen sich für veröffentlichbare redaktionelle Einwände. Wer die Entscheidung des Projektverantwortlichen bestreitet, braucht eine Stelle außerhalb seiner Entscheidungskette. Zuständigkeit, Befugnis zur Pause und sichere Kontaktwege müssen vor einem Pilot mit Teilnehmenden überprüfbar eingerichtet sein. Gesetzliche Rechtsbehelfe bleiben ein eigenständiger Weg. [11] [12]

Für Moderation gelten veröffentlichte Regeln, nachvollziehbare Begründungen und menschliche Überprüfung. Ein Minderheitenvotum bleibt auffindbar. Konkrete Drohungen und die Offenlegung privater Daten werden als eigene Schutzfälle behandelt.

Dissens unter Last

Die technische Idee lässt sich auf einen Baum von Fragen und auf Abhängigkeiten zwischen Aussagen übertragen. Ein neuer Einwand kann eine Voraussetzung treffen, auf der mehrere Folgerungen beruhen. Eine solche Änderung sollte die betroffenen Folgerungen erneut zur Prüfung öffnen. Die Projektarchitektur beschreibt diesen Ansatz. Eine belastbare öffentliche Umsetzung und ihre Wirksamkeit unter hoher Last stehen aus. [8] [16]

Wie gleiches Gehör beobachtbar wird

Jeder zugelassene Beitrag soll einen nachvollziehbaren Status erhalten. Ein eigenständiger Einwand bleibt auffindbar, auch wenn viele ähnliche Meldungen zusammengefasst werden. Eine Person kann die Zuordnung ihres Einwands prüfen und korrigieren lassen. Ein einziger belegter Gegenfall kann die Sachbewertung ändern. Die Zahl der Konten, Beiträge und KI-Ausgaben sagt für sich wenig über Belege oder die Zustimmung betroffener Menschen.

Belastungstest	Was das System zeigen müsste
Sehr viele Wiederholungen einer Meldung	Gemeinsame Herkunft erkennbar machen und einen neuen Einwand weiterhin bearbeiten.
Spät eingereichter, gut belegter Minderheiteneinwand	Auffindbarkeit, zuständige Prüfung und gegebenenfalls Revision dokumentieren.
Sprachfehler oder Ausfall eines Eingangskanals	Fehler sichtbar machen und einen erreichbaren Korrektur- oder Ausweichweg eröffnen.
Einspruch gegen eine Entscheidung des Betreibers	Bearbeitung durch eine Stelle zeigen, die die Entscheidung tatsächlich revidieren kann.

Ein erster Belastungstest vergleicht das Verfahren mit einer einfachen Eingangsreihenfolge bei gleichem Personal- und Zeitbudget. Vorab werden zulässige Wartezeiten, verlorene oder falsch zusammengelegte Einwände und Fehlalarme definiert. Durchsatz und Wartezeit werden neben der Qualität der Bearbeitung berichtet. Eine Häufung von Verlusten in einer Sprache oder einem Zugangsweg würde die Ausweitung des betreffenden Verfahrens blockieren.

DIE BRÜCKE ZURÜCK ZUM ERSTEN VERSUCH

Wenn viele Agenten dieselbe Quelle verwenden oder alle Beschwerdewege zur gleichen entscheidenden Person führen, fehlt im entscheidenden Moment die unabhängige Gegenprobe.

Was sich jetzt prüfen lässt

Wir legen einen technischen Befund, seine Grenzen und ein gestuftes Prüfprogramm vor. Zuerst lassen sich der Softwareversuch und die dokumentierten Entscheidungen nachvollziehen. Danach lässt sich prüfen, ob externe Belege und korrigierte Dokumentation in neuen Sitzungen einen Unterschied machen. Ein Versuch mit Menschen hängt von eigener Risiko- und Zugangsprüfung, unabhängiger Aufsicht und einem geeigneten Vergleich ab.

Drei Fragen an die fachliche Prüfung

1. Welche Gegenproben würden eine überzeugende Korrektur von bloß plausibler Überarbeitung unterscheiden?

2. Welche Vorkehrungen braucht ein Pilot, damit auch ein Mensch mit wenig Zeit, geringer Sprachsicherheit oder einem unbequemen Einwand eine echte Korrekturmöglichkeit hat?

3. Welche Evidenz und welche Verantwortlichkeit wären erforderlich, bevor ein solches Werkzeug von freiwilligen Zweierdialogen in größere Beteiligungsverfahren übergeht?

English summary

Vera is an open-source software project investigating whether AI-assisted correction can help people understand disagreements. A reproducible test of a deterministic publication checker found four wrong verdicts in 18 synthetic cases with one reversed input. A second test shows how apparently separate routes can share a single point of failure. A documented change to the project’s principles shows how an objection about long-term support can change a rule. The effects on people remain to be tested.

We propose separate studies of evidence-based revision, transfer to fresh sessions and mutual understanding in voluntary, low-risk dialogues. Agreement is optional. Independent oversight, accessible correction, preserved dissent and a private reporting route are prerequisites for a participant pilot. We invite expert feedback on the comparisons, safeguards and criteria for proceeding to larger settings.

Projekt Vera · KI-gestützte Ausarbeitung aus öffentlichen Projektquellen. Die Fallstudien sind interne Untersuchungen. Eine unabhängige fachliche Begutachtung und die vorgeschlagenen Versuche stehen aus.

Reproduktion und Projektquellen

Technische Befunde wiederholen

```
git clone https://github.com/AlexanderR1991/Vera.git
cd Vera
git checkout --detach 99b2ec2d12d7e02f5f055e3b28fd93c15bd9133b
node scripts/probe-vera-selbststudie.mjs
node --test tests/vera-self-model.test.mjs tests/metapher.test.mjs
```

Die Auszählung der 42 Eingaben und die sieben Tests wurden mit Node.js 24.22.1 erneut ausgeführt. Versuch und Tests nutzen keine Live-Abfrage und kein Sprachmodell. Der Reproduktionscommit ergänzt das Versuchsskript zur untersuchten Komponente. [2] [3]

[1] Projekt Vera. Frühere Fassungen dieses Papiers (November 2026). Selbststudie 1.0 · Diskussionspapier 2.0

[2] Veröffentlichungsmodell und 42-Fälle-Probe im fixierten Projektstand. Spezifikation · Versuchsskript · Tests

[3] Metaphernmodul und konstruierte Transferfälle. Modul · Tests

[4] Änderung zur Hilfe und dauerhaften Unterstützung, G-005. Versionsvergleich · Grundtext

[5] Vera als Projektrolle und versioniertes Projektgedächtnis. Projektprofil · Gedächtnisregister

[6] Selbstkorrektur und Entitätsprototyp. Regelkreis · Prototyp · Quellcode

[7] Vermittlungsprototyp und Plan für getrennte Geräte. Vermittlung

[8] WIRKLICH und seine getrennten Prüfdimensionen. Mathematische Spezifikation

[10] Separater Entwurf zur Evaluation über Aufgaben hinweg. Evaluationsprotokoll

[11] Verantwortung und bestehende Lücken bei Beschwerden. Projektordnung

[16] Vorschläge zur kollektiven Intelligenz und zu künftigen Fähigkeiten. Architektur · AGI-Horizont

[17] Philosophische Methode und die Fürsorge als begründete, revidierbare Projektorientierung. Prüfmaßstäbe · Liebe als Richtung

Projekt- und Codeverweise in dieser Fassung zeigen, soweit möglich, auf fixierte Git-Stände. Text nach CC BY-SA 4.0.

Fachliteratur und Europarat

[9] Empirische Arbeiten zur Korrektur von Sprachmodellausgaben.

Madaan, A. et al. (2023). *Self-Refine: Iterative Refinement with Self-Feedback.* NeurIPS 36. Konferenzbeitrag

Huang, J. et al. (2024). *Large Language Models Cannot Self-Correct Reasoning Yet.* ICLR 2024. Konferenzbeitrag

Gou, Z. et al. (2024). *CRITIC: Large Language Models Can Self-Correct with Tool-Interactive Critiquing.* ICLR 2024. Konferenzbeitrag

[12] Europarat (2024). Rahmenübereinkommen über künstliche Intelligenz und Menschenrechte, Demokratie und Rechtsstaatlichkeit, CETS Nr. 225. Vertragstext · Deutsche Übersetzung

[13] Ministerkomitee des Europarats (2023). Empfehlung CM/Rec(2023)6 zur deliberativen Demokratie, insbesondere Anhang, Grundsätze 3–8. Empfehlung

[14] Europarat. HUDERIA Methodology and Model. Arbeitshilfen für Kontextanalyse, Beteiligung betroffener Gruppen, Folgenabschätzung und Risikominderung. Methodik und Materialien

[15] Tessler, M. H. et al. (2024). *AI can help humans find common ground in democratic deliberation.* Science 386(6719), eadq2852. DOI 10.1126/science.adq2852

Leseschlüssel für die Evidenz

Die Veröffentlichungssimulation und die Brückenprobe beschreiben beobachtetes Programmverhalten in definierten Fällen. Die Änderung an G-005 ist eine dokumentierte redaktionelle Revision. Die externen Studien begründen Vergleichsfragen. Die Regelvorschläge und Schutzbedingungen sind normativ. Die geplanten Versuche und der Betrieb unter Last haben einen eigenen, noch offenen Prüfstatus.